

# Métodos Iterativos para Solução de Sistemas Lineares

## INF1608 – Análise Numérica

Waldemar Celes  
celes@inf.puc-rio.br

Departamento de Informática, PUC-Rio



# Tópicos

Fatoração de Cholesky

Métodos Iterativos

Método dos Gradientes Conjugados



# Fatoração de Cholesky



# Sistemas lineares

## Métodos de fatoração

- ▶ Fatoração LU
  - ▶ Aplicado a matrizes cheias
- ▶ Podemos diminuir o espaço de memória da fatoração?
  - ▶ Se  $A$  for simétrica, é possível usar metade do espaço?



# Sistemas lineares

## Métodos de fatoração

- ▶ Fatoração LU
  - ▶ Aplicado a matrizes cheias
- ▶ Podemos diminuir o espaço de memória da fatoração?
  - ▶ Se  $A$  for simétrica, é possível usar metade do espaço?
- ▶ Sim, com **Fatoração de Cholesky**,  
se matriz for **simétrica positiva definida**



# Sistemas de Equações Lineares

## Matriz Simétrica Positiva Definida

$$\mathbf{x}^T A \mathbf{x} > 0, \quad \forall \quad \mathbf{x} \neq \mathbf{0}$$

Propriedades:

1. Elementos da diagonal principal são positivos
2. Autovalores são todos positivos
3. Qualquer submatriz principal é também positiva definida



# Fatoração de Cholesky

Dada a matriz  $A$  simétrica positiva definida

- Objetivo: encontrar matriz triangular superior  $R$  tal que:

$$A = R^T R$$



# Fatoração de Cholesky

Dada a matriz  $A$  simétrica positiva definida

- Objetivo: encontrar matriz triangular superior  $R$  tal que:

$$A = R^T R$$

---

Caso  $n = 2$ :

$$A = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$$





# Fatoração de Cholesky

Dada a matriz  $A$  simétrica positiva definida

- Objetivo: encontrar matriz triangular superior  $R$  tal que:

$$A = R^T R$$

---

Caso  $n = 2$ :

$$A = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$$

$$\begin{bmatrix} a & b \\ b & c \end{bmatrix} = \begin{bmatrix} \sqrt{a} & 0 \\ u & v \end{bmatrix} \begin{bmatrix} \sqrt{a} & u \\ 0 & v \end{bmatrix} = \begin{bmatrix} a & u\sqrt{a} \\ u\sqrt{a} & u^2 + v^2 \end{bmatrix}$$



# Fatoração de Cholesky

Dada a matriz  $A$  simétrica positiva definida

- Objetivo: encontrar matriz triangular superior  $R$  tal que:

$$A = R^T R$$

---

Caso  $n = 2$ :

$$A = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$$

$$\begin{bmatrix} a & b \\ b & c \end{bmatrix} = \begin{bmatrix} \sqrt{a} & 0 \\ u & v \end{bmatrix} \begin{bmatrix} \sqrt{a} & u \\ 0 & v \end{bmatrix} = \begin{bmatrix} a & u\sqrt{a} \\ u\sqrt{a} & u^2 + v^2 \end{bmatrix}$$

$$b = u\sqrt{a} \quad \therefore \quad u = \frac{b}{\sqrt{a}}$$

$$c = \frac{b^2}{a} + v^2 \quad \therefore \quad v = \sqrt{c - \frac{b^2}{a}}$$



# Fatoração de Cholesky

Caso  $n \times n$ :

$$A = \left[ \begin{array}{c|c} a & \mathbf{b}^T \\ \hline \mathbf{b} & C \end{array} \right]$$



# Fatoração de Cholesky

Caso  $n \times n$ :

$$A = \left[ \begin{array}{c|c} a & \mathbf{b}^T \\ \hline \mathbf{b} & C \end{array} \right]$$

$$\begin{aligned} R^T R &= \left[ \begin{array}{c|ccc} \sqrt{a} & 0 & \dots & 0 \\ \hline \mathbf{u} & & & V^T \end{array} \right] \left[ \begin{array}{c|c} \sqrt{a} & \mathbf{u}^T \\ \hline 0 & \\ \vdots & \\ 0 & V \end{array} \right] = \\ &= \left[ \begin{array}{c|c} a & \sqrt{a}\mathbf{u}^T \\ \hline \sqrt{a}\mathbf{u} & \mathbf{u}\mathbf{u}^T + V^T V \end{array} \right] \left\{ \begin{array}{l} \mathbf{u} = \frac{\mathbf{b}}{\sqrt{a}} \\ V^T V = C - \mathbf{u}\mathbf{u}^T = A_1 \end{array} \right. \end{aligned}$$



# Fatoração de Cholesky

## Procedimento

### ► Primeira linha

$$r_{00} = \sqrt{a_{00}}$$

$$\mathbf{u}^T = \frac{\mathbf{b}^T}{r_{00}}$$

$$A_1 = C - \mathbf{u}\mathbf{u}^T$$

### ► onde:

- $A_1$  é uma matriz  $(n-1) \times (n-1)$
- Por indução,  $A_1 = V^T V$ , onde  $V$  é triangular superior



# Fatoração de Cholesky

Algoritmo (fatoração *in place*)

- ▶ Entrada:  $A_{n \times n}$ , triangular
- ▶ Saída:  $R^T$ , triangular

**for**  $k = 0$  **to**  $n - 1$

$$A_{kk} = \sqrt{A_{kk}} \qquad = r_{kk}$$

**for**  $i = k + 1$  **to**  $n - 1$

$$A_{ik} = A_{ik} / A_{kk} \qquad = \mathbf{u} \text{ (vetor coluna)}$$

**for**  $i = k + 1$  **to**  $n - 1$

**for**  $j = k + 1$  **to**  $i$

$$A_{ij} = A_{ij} - A_{ik}A_{jk} \qquad = A_{ij} - \mathbf{u}\mathbf{u}^T$$



# Fatoração de Cholesky

Resolvendo o sistema

$$A\mathbf{x} = \mathbf{b}$$

$$R^T R\mathbf{x} = \mathbf{b}$$

$$\begin{cases} R^T \mathbf{y} = \mathbf{b} \\ R\mathbf{x} = \mathbf{y} \end{cases}$$

- ▶ Acha-se  $\mathbf{y}$  por **substituição progressiva**
- ▶ Acha-se  $\mathbf{x}$  por **substituição regressiva** (retro-substituição)



# Fatoração de Cholesky

Resolvendo o sistema

$$\begin{aligned} Ax &= \mathbf{b} \\ R^T R x &= \mathbf{b} \\ \begin{cases} R^T \mathbf{y} &= \mathbf{b} \\ R x &= \mathbf{y} \end{cases} \end{aligned}$$

- ▶ Acha-se  $\mathbf{y}$  por **substituição progressiva**
- ▶ Acha-se  $\mathbf{x}$  por **substituição regressiva** (retro-substituição)

## Observação

- ▶ Na fatoração de Cholesky, não é necessário uso de pivotamento





# Métodos Iterativos



# Sistemas Lineares

## Resolução de sistemas lineares

- ▶ Eliminação de Gauss
  - ▶ Método direto
  - ▶ Solução exata (teoricamente)
  - ▶ Complexidade computacional:  $O(n^3)$



# Sistemas Lineares

## Resolução de sistemas lineares

- ▶ Eliminação de Gauss
  - ▶ Método direto
  - ▶ Solução exata (teoricamente)
  - ▶ Complexidade computacional:  $O(n^3)$

## Métodos iterativos

- ▶ Solução, em geral, aproximada
- ▶ Complexidade computacional:  $m\delta$ 
  - ▶  $m$  é o número de iterações
  - ▶  $\delta$  é a complexidade em cada iteração



# Métodos Iterativos

Sistemas lineares

$$Ax = b$$

## Método de Jacobi

- ▶ Forma de iteração de ponto fixo para sistemas de equações
- ▶ Aplica IPF na  $i$ -ésima equação para achar  $x_i$



# Métodos Iterativos

Sistemas lineares

$$Ax = b$$

## Método de Jacobi

- ▶ Forma de iteração de ponto fixo para sistemas de equações
- ▶ Aplica IPF na  $i$ -ésima equação para achar  $x_i$

Exemplo:

$$\begin{cases} 3x + y = 5 \\ x + 2y = 5 \end{cases}$$



# Métodos Iterativos

Sistemas lineares

$$A\mathbf{x} = \mathbf{b}$$

## Método de Jacobi

- ▶ Forma de iteração de ponto fixo para sistemas de equações
- ▶ Aplica IPF na  $i$ -ésima equação para achar  $x_i$

Exemplo:

$$\begin{cases} 3x + y = 5 \\ x + 2y = 5 \end{cases}$$

Reescrevendo:

$$\begin{cases} x = \frac{5-y}{3} \\ y = \frac{5-x}{2} \end{cases}$$



# Métodos Iterativos

## Método de Jacobi

$$\begin{cases} x = \frac{5-y}{3} \\ y = \frac{5-x}{2} \end{cases}$$

Iterando:

$$\begin{bmatrix} x_0 \\ y_0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \rightarrow \begin{bmatrix} \frac{5}{3} \\ \frac{5}{2} \end{bmatrix} \rightarrow \begin{bmatrix} \frac{5}{6} \\ \frac{5}{3} \end{bmatrix} \rightarrow \begin{bmatrix} \frac{10}{9} \\ \frac{25}{12} \end{bmatrix} \rightarrow \dots$$



# Métodos Iterativos

## Método de Jacobi

$$\begin{cases} x = \frac{5-y}{3} \\ y = \frac{5-x}{2} \end{cases}$$

Iterando:

$$\begin{bmatrix} x_0 \\ y_0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \rightarrow \begin{bmatrix} \frac{5}{3} \\ \frac{5}{2} \end{bmatrix} \rightarrow \begin{bmatrix} \frac{5}{6} \\ \frac{5}{3} \end{bmatrix} \rightarrow \begin{bmatrix} \frac{10}{9} \\ \frac{25}{12} \end{bmatrix} \rightarrow \dots$$

- ▶ Converge!
- ▶ Solução exata:

$$\begin{bmatrix} 1 \\ 2 \end{bmatrix}$$





# Métodos Iterativos

## Método de Jacobi

- ▶ Invertendo a ordem das equações

Exemplo:

$$\begin{cases} x + 2y = 5 \\ 3x + y = 5 \end{cases}$$



# Métodos Iterativos

## Método de Jacobi

- ▶ Invertendo a ordem das equações

Exemplo:

$$\begin{cases} x + 2y = 5 \\ 3x + y = 5 \end{cases}$$

Reescrevendo:

$$\begin{cases} x = 5 - 2y \\ y = 5 - 3x \end{cases}$$



# Métodos Iterativos

## Método de Jacobi

- Invertendo a ordem das equações

Exemplo:

$$\begin{cases} x + 2y = 5 \\ 3x + y = 5 \end{cases}$$

Reescrevendo:

$$\begin{cases} x = 5 - 2y \\ y = 5 - 3x \end{cases}$$

Iterando:

$$\begin{bmatrix} x_0 \\ y_0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \rightarrow \begin{bmatrix} 5 \\ 5 \end{bmatrix} \rightarrow \begin{bmatrix} -5 \\ 10 \end{bmatrix} \rightarrow \begin{bmatrix} 25 \\ 20 \end{bmatrix} \rightarrow \dots$$



# Métodos Iterativos

## Método de Jacobi

- Invertendo a ordem das equações

Exemplo:

$$\begin{cases} x + 2y = 5 \\ 3x + y = 5 \end{cases}$$

Reescrevendo:

$$\begin{cases} x = 5 - 2y \\ y = 5 - 3x \end{cases}$$

Iterando:

$$\begin{bmatrix} x_0 \\ y_0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \rightarrow \begin{bmatrix} 5 \\ 5 \end{bmatrix} \rightarrow \begin{bmatrix} -5 \\ 10 \end{bmatrix} \rightarrow \begin{bmatrix} 25 \\ 20 \end{bmatrix} \rightarrow \dots$$

- Não converge!



# Métodos Iterativos

Definição: **Matriz Estritamente Diagonal Dominante**

- ▶ Uma matriz  $A_{n \times n}$  é estritamente diagonal dominante se:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|$$

- ▶ Isto é, o valor absoluto da diagonal é maior que a soma dos valores absolutos dos demais elementos da linha da matriz

No exemplo:

- ▶ 1o caso:

$$\begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

- ▶ 2o caso:

$$\begin{bmatrix} 1 & 2 \\ 3 & 1 \end{bmatrix}$$



# Métodos Iterativos

Definição: **Matriz Estritamente Diagonal Dominante**

- ▶ Uma matriz  $A_{n \times n}$  é estritamente diagonal dominante se:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|$$

- ▶ Isto é, o valor absoluto da diagonal é maior que a soma dos valores absolutos dos demais elementos da linha da matriz

No exemplo:

- ▶ 1o caso:

$$\begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

- ▶ 2o caso:

$$\begin{bmatrix} 1 & 2 \\ 3 & 1 \end{bmatrix}$$

- ▶ O método de Jacobi converge se a matriz for estritamente diagonal dominante



# Métodos Iterativos

## Formulação do Método de Jacobi

$$A\mathbf{x} = \mathbf{b}$$

- Decomposição da matriz

$$A = L + D + U$$

- $L$ : matriz com os elementos abaixo da diagonal
- $D$ : matriz com os elementos da diagonal
- $U$ : matriz com os elementos acima da diagonal



# Métodos Iterativos

## Formulação do Método de Jacobi

$$A\mathbf{x} = \mathbf{b}$$

- ▶ Decomposição da matriz

$$A = L + D + U$$

- ▶  $L$ : matriz com os elementos abaixo da diagonal
- ▶  $D$ : matriz com os elementos da diagonal
- ▶  $U$ : matriz com os elementos acima da diagonal
- ▶ Reescrevendo algebricamente:

$$A\mathbf{x} = \mathbf{b}$$

$$(D + L + U)\mathbf{x} = \mathbf{b}$$

$$D\mathbf{x} = \mathbf{b} - (L + U)\mathbf{x}$$

$$\mathbf{x} = D^{-1}(\mathbf{b} - (L + U)\mathbf{x})$$





# Métodos Iterativos

## Formulação do Método de Jacobi

$$A\mathbf{x} = \mathbf{b}$$

- ▶ Decomposição da matriz

$$A = L + D + U$$

- ▶  $L$ : matriz com os elementos abaixo da diagonal
- ▶  $D$ : matriz com os elementos da diagonal
- ▶  $U$ : matriz com os elementos acima da diagonal
- ▶ Reescrevendo algebricamente:

$$A\mathbf{x} = \mathbf{b}$$

$$(D + L + U)\mathbf{x} = \mathbf{b}$$

$$D\mathbf{x} = \mathbf{b} - (L + U)\mathbf{x}$$

$$\mathbf{x} = D^{-1}(\mathbf{b} - (L + U)\mathbf{x})$$

- ▶ Note que  $D$  tem inversa trivial



# Métodos Iterativos

Algoritmo: Método de Jacobi

$\mathbf{x}_0$  = estimativa inicial

$$\mathbf{x}_{k+1} = D^{-1}(\mathbf{b} - (L + U)\mathbf{x}_k), \quad k = 1, 2, 3, \dots$$



# Métodos Iterativos

Algoritmo: Método de Jacobi

$\mathbf{x}_0$  = estimativa inicial

$$\mathbf{x}_{k+1} = D^{-1}(\mathbf{b} - (L + U)\mathbf{x}_k), \quad k = 1, 2, 3, \dots$$

No exemplo:

$$\begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}$$



# Métodos Iterativos

Algoritmo: Método de Jacobi

$\mathbf{x}_0$  = estimativa inicial

$$\mathbf{x}_{k+1} = D^{-1}(\mathbf{b} - (L + U)\mathbf{x}_k), \quad k = 1, 2, 3, \dots$$

No exemplo:

$$\begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}$$

$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \end{bmatrix} = \begin{bmatrix} \frac{1}{3} & 0 \\ 0 & \frac{1}{2} \end{bmatrix} \left( \begin{bmatrix} 5 \\ 5 \end{bmatrix} - \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} x_k \\ y_k \end{bmatrix} \right) = \begin{bmatrix} \frac{5-y_k}{3} \\ \frac{5-x_k}{2} \end{bmatrix}$$



# Métodos Iterativos

## Método de Gauss-Seidel

- ▶ Iteração de Jacobi que usa valores mais recentes dentro da mesma iteração
  - ▶ Impede computação em paralelo
- ▶ Convergência mais rápida, em geral
  - ▶ Ainda condicionada a matriz estritamente diagonal dominante



# Métodos Iterativos

## Método de Gauss-Seidel

- ▶ Iteração de Jacobi que usa valores mais recentes dentro da mesma iteração
  - ▶ Impede computação em paralelo
- ▶ Convergência mais rápida, em geral
  - ▶ Ainda condicionada a matriz estritamente diagonal dominante

Exemplo:

$$\begin{cases} 3x + y = 5 \\ x + 2y = 5 \end{cases}$$



# Métodos Iterativos

## Método de Gauss-Seidel

- ▶ Iteração de Jacobi que usa valores mais recentes dentro da mesma iteração
  - ▶ Impede computação em paralelo
- ▶ Convergência mais rápida, em geral
  - ▶ Ainda condicionada a matriz estritamente diagonal dominante

Exemplo:

$$\begin{cases} 3x + y = 5 \\ x + 2y = 5 \end{cases}$$

Jacobi:

$$\begin{cases} x_{i+1} = \frac{5-y_i}{3} \\ y_{i+1} = \frac{5-x_i}{2} \end{cases}$$



# Métodos Iterativos

## Método de Gauss-Seidel

- ▶ Iteração de Jacobi que usa valores mais recentes dentro da mesma iteração
  - ▶ Impede computação em paralelo
- ▶ Convergência mais rápida, em geral
  - ▶ Ainda condicionada a matriz estritamente diagonal dominante

Exemplo:

$$\begin{cases} 3x + y = 5 \\ x + 2y = 5 \end{cases}$$

Jacobi:

$$\begin{cases} x_{i+1} = \frac{5-y_i}{3} \\ y_{i+1} = \frac{5-x_i}{2} \end{cases}$$

Gauss-Seidel:

$$\begin{cases} x_{i+1} = \frac{5-y_i}{3} \\ y_{i+1} = \frac{5-x_{i+1}}{2} \end{cases}$$





# Métodos Iterativos

Exemplo:

$$\begin{cases} x = \frac{5-y}{3} \\ y = \frac{5-x}{2} \end{cases}$$

Iterações de Jacobi:

$$\begin{bmatrix} x_0 \\ y_0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \rightarrow \begin{bmatrix} \frac{5}{3} \\ \frac{5}{2} \end{bmatrix} \rightarrow \begin{bmatrix} \frac{5}{6} \\ \frac{5}{3} \end{bmatrix} \rightarrow \begin{bmatrix} \frac{10}{9} \\ \frac{25}{12} \end{bmatrix} = \begin{bmatrix} 1.1111 \\ 2.0833 \end{bmatrix}$$



# Métodos Iterativos

Exemplo:

$$\begin{cases} x = \frac{5-y}{3} \\ y = \frac{5-x}{2} \end{cases}$$

Iterações de Jacobi:

$$\begin{bmatrix} x_0 \\ y_0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \rightarrow \begin{bmatrix} \frac{5}{3} \\ \frac{5}{2} \end{bmatrix} \rightarrow \begin{bmatrix} \frac{5}{6} \\ \frac{5}{3} \end{bmatrix} \rightarrow \begin{bmatrix} \frac{10}{9} \\ \frac{25}{12} \end{bmatrix} = \begin{bmatrix} 1.1111 \\ 2.0833 \end{bmatrix}$$

Iterações de Gauss-Seidel:

$$\begin{bmatrix} x_0 \\ y_0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \rightarrow \begin{bmatrix} \frac{5}{3} \\ \frac{5}{3} \end{bmatrix} \rightarrow \begin{bmatrix} \frac{10}{9} \\ \frac{35}{18} \end{bmatrix} \rightarrow \begin{bmatrix} \frac{55}{54} \\ \frac{215}{108} \end{bmatrix} = \begin{bmatrix} 1.0185 \\ 1.9907 \end{bmatrix}$$



# Métodos Iterativos

Algoritmo: Método de Gauss-Seidel

$\mathbf{x}_0 =$  estimativa inicial

$$\mathbf{x}_{k+1} = D^{-1}(\mathbf{b} - U\mathbf{x}_k - L\mathbf{x}_{k+1}), \quad k = 1, 2, 3, \dots$$

$$- \begin{bmatrix} \text{Upper triangular matrix } U \\ \text{Diagonal band} \end{bmatrix} \begin{bmatrix} \text{Vector } \mathbf{x}_k \end{bmatrix} - \begin{bmatrix} \text{Lower triangular matrix } L \\ \text{Diagonal band} \end{bmatrix} \begin{bmatrix} \text{Vector } \mathbf{x}_{k+1} \end{bmatrix}$$

$U \qquad \mathbf{x}_k \qquad L \qquad \mathbf{x}_{k+1}$

- Na prática, trabalha-se com um único vetor (*in place*)



# Métodos Iterativos

## Relaxação sucessiva

$$\mathbf{x}_{k+1} = (1 - w)\mathbf{x}_k + w [\text{fórmula para determinar } \mathbf{x}_{k+1}]$$



# Métodos Iterativos

## Relaxação sucessiva

$$\mathbf{x}_{k+1} = (1 - w)\mathbf{x}_k + w [\text{fórmula para determinar } \mathbf{x}_{k+1}]$$

- ▶ Se  $w < 1$ , tem-se sub-relaxação (interpolação)
- ▶ Se  $w > 1$ , tem-se sobre-relaxação (extrapolação)



# Métodos Iterativos

## Relaxação sucessiva

$$\mathbf{x}_{k+1} = (1 - w)\mathbf{x}_k + w [\text{fórmula para determinar } \mathbf{x}_{k+1}]$$

- ▶ Se  $w < 1$ , tem-se sub-relaxação (interpolação)
  - ▶ Usado para convergir sistemas não convergentes ou acelerar a convergência amortecendo oscilações
- ▶ Se  $w > 1$ , tem-se sobre-relaxação (extrapolação)



# Métodos Iterativos

## Relaxação sucessiva

$$\mathbf{x}_{k+1} = (1 - w)\mathbf{x}_k + w [\text{fórmula para determinar } \mathbf{x}_{k+1}]$$

- ▶ Se  $w < 1$ , tem-se sub-relaxação (interpolação)
  - ▶ Usado para convergir sistemas não convergentes ou acelerar a convergência amortecendo oscilações
- ▶ Se  $w > 1$ , tem-se sobre-relaxação (extrapolação)
  - ▶ Usado para acelerar convergência de um sistema convergente
  - ▶ Esta estratégia é muito usada!



# Métodos Iterativos

## Custo computacional

- ▶ Custo por iteração:  $O(n^2)$ 
  - ▶ Operação dominante: multiplicação de matriz por vetor
- ▶ Custo total:  $mO(n^2)$





# Métodos Iterativos

## Custo computacional

- ▶ Custo por iteração:  $O(n^2)$ 
  - ▶ Operação dominante: multiplicação de matriz por vetor
- ▶ Custo total:  $mO(n^2)$
- ▶ Em condições especiais
  - ▶ **Sistemas esparsos**
    - ▶ Complexidade de cada interação:  $O(n)$
  - ▶ **Sistemas coerentes** (boas estimativas iniciais)
    - ▶ Número de iterações:  $O(1)$
  - ▶ Complexidade computacional total:  $O(n)$



# Métodos Iterativos

## Sistemas esparsos

- ▶ Matriz com a grande maioria dos elementos nulos
- ▶ Armazenar e processar apenas os elementos não nulos
  - ▶ Eliminação de Gauss transformaria em matriz cheia



# Métodos Iterativos

## Sistemas esparsos

- ▶ Matriz com a grande maioria dos elementos nulos
- ▶ Armazenar e processar apenas os elementos não nulos
  - ▶ Eliminação de Gauss transformaria em matriz cheia

### Exemplo

$$\begin{bmatrix}
 3 & -1 & 0 & \cdots & 0 & 0 & 0.5 \\
 -1 & 3 & -1 & \cdots & 0 & 0.5 & 0 \\
 0 & -1 & 3 & \cdots & 0.5 & 0 & 0 \\
 & & & \ddots & & & \\
 0 & 0 & 0.5 & \cdots & 3 & -1 & 0 \\
 0 & 0.5 & 0 & \cdots & -1 & 3 & -1 \\
 0.5 & 0 & 0 & \cdots & 0 & -1 & 3
 \end{bmatrix} \mathbf{x} = \begin{bmatrix} 2.5 \\ 1.5 \\ 1.5 \\ \vdots \\ 1.5 \\ 1.5 \\ 2.5 \end{bmatrix}, \text{ solução } \mathbf{x} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ \vdots \\ 1 \\ 1 \\ 1 \end{bmatrix}$$



# Métodos Iterativos

## Sistemas esparsos

Exemplo:  $n = 100\,000$

- ▶ Matriz cheia:  $n^2 = 10^{10}$  valores
  - ▶ Memória:  $8 \times 10^{10} = 80$  Gbytes!
  - ▶ Processamento por Eliminação de Gauss  $O(n^3)$ 
    - ▶  $10^{15}$  operações



# Métodos Iterativos

## Sistemas esparsos

Exemplo:  $n = 100\,000$

- ▶ Matriz cheia:  $n^2 = 10^{10}$  valores
  - ▶ Memória:  $8 \times 10^{10} = 80$  Gbytes!
  - ▶ Processamento por Eliminação de Gauss  $O(n^3)$ 
    - ▶  $10^{15}$  operações
  - ▶ Suponha máquina de  $10^8$  flops
    - ▶ Tempo de processamento:  $\frac{10^{15}}{10^8} = 10^7$  segundos!
    - ▶ Um ano tem  $3 \times 10^7$  segundos



# Métodos Iterativos

## Sistemas esparsos

Exemplo:  $n = 100\,000$

- ▶ Matriz cheia:  $n^2 = 10^{10}$  valores
  - ▶ Memória:  $8 \times 10^{10} = 80$  Gbytes!
  - ▶ Processamento por Eliminação de Gauss  $O(n^3)$ 
    - ▶  $10^{15}$  operações
  - ▶ Suponha máquina de  $10^8$  flops
    - ▶ Tempo de processamento:  $\frac{10^{15}}{10^8} = 10^7$  segundos!
    - ▶ Um ano tem  $3 \times 10^7$  segundos
- ▶ Considerando esparsidade da matriz
  - ▶ Memória:  $4n$
  - ▶ Número de operações:  $2 \times 4n = 8 \times 10^5$ 
    - ▶  $\approx 1$  segundo por iteração!



# Método dos Gradientes Conjugados



# Reformulando o Problema

Sistema linear

$$A\mathbf{x} = \mathbf{b}$$

Exemplo:

$$\begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix} \mathbf{x} = \begin{bmatrix} 2 \\ -8 \end{bmatrix}$$





# Reformulando o Problema

Sistema linear

$$A\mathbf{x} = \mathbf{b}$$

Exemplo:

$$\begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix} \mathbf{x} = \begin{bmatrix} 2 \\ -8 \end{bmatrix}$$

► Solução:

$$\mathbf{x} = \begin{bmatrix} 2 \\ -2 \end{bmatrix}$$

Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994



# Reformulando o Problema

Sistema linear

$$A\mathbf{x} = \mathbf{b}$$

Exemplo:

$$\begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix} \mathbf{x} = \begin{bmatrix} 2 \\ -8 \end{bmatrix}$$

► Solução:

$$\mathbf{x} = \begin{bmatrix} 2 \\ -2 \end{bmatrix}$$

- Interpretação geométrica
  - Interseção dos hiperplanos




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994



# Reformulando o Problema

## Forma Quadrática

- Equação escalar na forma:

$$f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T A \mathbf{x} - \mathbf{b}^T \mathbf{x} + c$$

- onde  $c$  é um valor escalar (p.e.  $c = 0$ )



Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994



# Reformulando o Problema

## Forma Quadrática

- Equação escalar na forma:

$$f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T A \mathbf{x} - \mathbf{b}^T \mathbf{x} + c$$

- onde  $c$  é um valor escalar (p.e.  $c = 0$ )




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

# Reformulando o Problema

Gradiente da forma quadrática

$$f'(\mathbf{x}) = A\mathbf{x} - b$$



---

Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994



# Reformulando o Problema

Gradiente da forma quadrática

$$f'(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$$

- ▶ Ponto crítico da forma quadrática

$$f'(\mathbf{x}) = 0$$

- ▶ que equivale a achar a solução de  $A\mathbf{x} = \mathbf{b}$



# Reformulando o Problema

Gradiente da forma quadrática

$$f'(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$$

- ▶ Ponto crítico da forma quadrática

$$f'(\mathbf{x}) = 0$$

- ▶ que equivale a achar a solução de  $A\mathbf{x} = \mathbf{b}$
- ▶ Sendo  $A$  positiva definida, será sempre um **ponto de mínimo**

$$\mathbf{x}^T A \mathbf{x} > 0, \quad \forall \quad \mathbf{x} \neq \mathbf{0}$$



Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994



# Reformulando o Problema

Gradiente da forma quadrática

$$f'(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$$

- ▶ Ponto crítico da forma quadrática

$$f'(\mathbf{x}) = 0$$

- ▶ que equivale a achar a solução de  $A\mathbf{x} = \mathbf{b}$
- ▶ Sendo  $A$  positiva definida, será sempre um **ponto de mínimo**

$$\mathbf{x}^T A \mathbf{x} > 0, \quad \forall \quad \mathbf{x} \neq \mathbf{0}$$

*Determinar a solução de  $A\mathbf{x} = \mathbf{b}$   
é equivalente a encontrar o ponto  
mínimo de  $f(\mathbf{x})$*




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994



# Determinação do Mínimo da Função

Erro da solução

$$\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}_s$$

Resíduo

$$\mathbf{r}_k = \mathbf{b} - A\mathbf{x}_k$$

Logo:

$$\mathbf{r}_k = \mathbf{b} - A(\mathbf{e}_k + \mathbf{x}_s)$$

$$\mathbf{r}_k = -A\mathbf{e}_k$$

- O resíduo é o erro transformado por  $A$  no espaço de  $\mathbf{b}$



# Determinação do Mínimo da Função

Tomar a direção inversa do gradiente

- Converge, mas resulta em muitas iterações




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994



# Determinação do Mínimo da Função

Buscar as direções ortogonais  $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$

- ▶ Erro expresso como combinação linear de  $\mathbf{d}'_k$ s
- ▶ Um passo em cada direção
  - ▶ Elimina cada componente do erro na direção  $\mathbf{d}_k$



Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994



# Determinação do Mínimo da Função

Buscar as direções ortogonais  $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$

- ▶ Erro expresso como combinação linear de  $\mathbf{d}'_k$ s
- ▶ Um passo em cada direção
  - ▶ Elimina cada componente do erro na direção  $\mathbf{d}_k$

Procedimento

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

# Determinação do Mínimo da Função

Buscar as direções ortogonais  $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$

- ▶ Erro expresso como combinação linear de  $\mathbf{d}'_k$ s
- ▶ Um passo em cada direção
  - ▶ Elimina cada componente do erro na direção  $\mathbf{d}_k$

Procedimento

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

- ▶ Determinação de  $\alpha_k$ 
  - ▶  $\mathbf{e}_{k+1}$  ortogonal a  $\mathbf{d}_k$

$$\mathbf{d}_k^T \mathbf{e}_{k+1} = 0$$

$$\mathbf{d}_k^T (\mathbf{e}_k + \alpha_k \mathbf{d}_k) = 0$$

$$\alpha_k = -\frac{\mathbf{d}_k^T \mathbf{e}_k}{\mathbf{d}_k^T \mathbf{d}_k}$$




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

# Determinação do Mínimo da Função

Buscar as direções ortogonais  $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$

- ▶ Erro expresso como combinação linear de  $\mathbf{d}'_k$ s
- ▶ Um passo em cada direção
  - ▶ Elimina cada componente do erro na direção  $\mathbf{d}_k$

Procedimento

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

▶ Determinação de  $\alpha_k$

▶  $\mathbf{e}_{k+1}$  ortogonal a  $\mathbf{d}_k$

$$\mathbf{d}_k^T \mathbf{e}_{k+1} = 0$$

$$\mathbf{d}_k^T (\mathbf{e}_k + \alpha_k \mathbf{d}_k) = 0$$

$$\alpha_k = -\frac{\mathbf{d}_k^T \mathbf{e}_k}{\mathbf{d}_k^T \mathbf{d}_k}$$

▶ Mas não conhecemos  $\mathbf{e}_k$




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

# Determinação do Mínimo da Função

## Solução

- Busca em direções ortogonais em  $A$
- Conjugados em  $A$

$$\mathbf{d}_i^T \mathbf{A} \mathbf{d}_j = 0$$




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

# Método dos Gradientes Conjugados

## Método Gradiente Conjugado

- ▶ Aplicado a sistema cuja matriz é simétrica positiva definida





# Método dos Gradientes Conjugados

## Método Gradiente Conjugado

- ▶ Aplicado a sistema cuja matriz é simétrica positiva definida
- ▶ Dada uma estimativa inicial  $\mathbf{x}_0$ 
  - ▶ Elimina, um a um, os  $n$  componentes ortogonais do erro



# Método dos Gradientes Conjugados

## Método Gradiente Conjugado

- ▶ Aplicado a sistema cuja matriz é simétrica positiva definida
- ▶ Dada uma estimativa inicial  $\mathbf{x}_0$ 
  - ▶ Elimina, um a um, os  $n$  componentes ortogonais do erro
- ▶ Método direto *versus* iterativo
  - ▶ Converge para solução exata após  $n$  iterações
  - ▶ Resultado pode ser satisfatório antes de  $n$  iterações
    - ▶ Considerando uma determinada tolerância numérica



# Método Gradiente Conjugado

Definição: **Produto escalar em  $A$**

Sendo  $A$  uma matriz simétrica positiva definida, dois vetores  $\mathbf{v}$  e  $\mathbf{w}$  de dimensão  $n$  definem um produto escalar em  $A$ :

$$(\mathbf{v}, \mathbf{w})_A = \mathbf{v}^T A \mathbf{w}$$

- $\mathbf{v}$  e  $\mathbf{w}$  são **ortogonais em  $A$  (conjugados)** se  $\mathbf{v}^T A \mathbf{w} = 0$ .



# Método Gradiente Conjugado

Definição: **Produto escalar em  $A$**

Sendo  $A$  uma matriz simétrica positiva definida, dois vetores  $\mathbf{v}$  e  $\mathbf{w}$  de dimensão  $n$  definem um produto escalar em  $A$ :

$$(\mathbf{v}, \mathbf{w})_A = \mathbf{v}^T A \mathbf{w}$$

- $\mathbf{v}$  e  $\mathbf{w}$  são **ortogonais em  $A$  (conjugados)** se  $\mathbf{v}^T A \mathbf{w} = 0$ .

*Lembrando que um produto interno entre dois vetores é zero se eles forem ortogonais*



# Método Gradiente Conjugado

Definição: **Produto escalar em  $A$**

Sendo  $A$  uma matriz simétrica positiva definida, dois vetores  $\mathbf{v}$  e  $\mathbf{w}$  de dimensão  $n$  definem um produto escalar em  $A$ :

$$(\mathbf{v}, \mathbf{w})_A = \mathbf{v}^T A \mathbf{w}$$

- ▶  $\mathbf{v}$  e  $\mathbf{w}$  são **ortogonais em  $A$  (conjugados)** se  $\mathbf{v}^T A \mathbf{w} = 0$ .

*Lembrando que um produto interno entre dois vetores é zero se eles forem ortogonais*

- ▶ Como  $A$  é simétrica:  $(\mathbf{v}, \mathbf{w})_A = (\mathbf{w}, \mathbf{v})_A$
- ▶ Como  $A$  é positiva definida:  $(\mathbf{v}, \mathbf{v})_A > 0 \quad \forall \mathbf{v} \neq 0$



# Método Gradiente Conjugado

Atualização do vetor solução

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

Atualização do vetor resíduo

► Sabe-se:

$$A\mathbf{x}_{k+1} + \mathbf{r}_{k+1} = A\mathbf{x}_k + \mathbf{r}_k$$

► Então:

$$A(\mathbf{x}_k + \alpha_k \mathbf{d}_k) + \mathbf{r}_{k+1} = A\mathbf{x}_k + \mathbf{r}_k$$

$$A\mathbf{x}_k + \alpha_k A\mathbf{d}_k + \mathbf{r}_{k+1} = A\mathbf{x}_k + \mathbf{r}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A\mathbf{d}_k$$



# Método Gradiente Conjugado

De fato:

- ▶ Vimos que o resíduo é o erro transformado por A:

$$\mathbf{r}_k = -A\mathbf{e}_k$$

- ▶ Sabemos que:

$$\mathbf{e}_{k+1} = \mathbf{e}_k + \alpha \mathbf{d}_k$$

- ▶ Logo:

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha A\mathbf{d}_k$$



# Método Gradiente Conjugado

## Premissas

- ▶  $\mathbf{d}_k$  deve ser ortogonal a  $\mathbf{r}_{k+1}$ 
  - ▶  $\mathbf{d}_k$  A-ortogonal a  $\mathbf{e}_{k+1}$

$$\mathbf{d}_k \perp \mathbf{r}_{k+1}$$

- ▶ Próxima direção de busca
  - ▶ Conjugados em pares

$$\mathbf{d}_{k+1}^T A \mathbf{d}_k = 0$$





# Método Gradiente Conjugado

Escolha de  $\alpha_k$

- Como  $\mathbf{d}_k$  deve ser ortogonal a  $\mathbf{r}_{k+1}$

$$\mathbf{d}_k^T \mathbf{r}_{k+1} = 0$$

$$\mathbf{d}_k^T (\mathbf{r}_k - \alpha_k A \mathbf{d}_k) = 0$$

$$\mathbf{d}_k^T \mathbf{r}_k = \alpha_k \mathbf{d}_k^T A \mathbf{d}_k$$

$$\therefore \alpha_k = \frac{\mathbf{d}_k^T \mathbf{r}_k}{\mathbf{d}_k^T A \mathbf{d}_k}$$



# Método Gradiente Conjugado

Escolha da nova direção de busca

- ▶ Resíduo é expresso por uma combinação linear de  $\mathbf{d}_k$ 's

$$\mathbf{d}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{d}_k$$

- ▶ Direções são conjugadas entre si

$$\mathbf{d}_{k+1}^T A \mathbf{d}_k = 0$$

- ▶ Assim, pré-multiplicando por  $\mathbf{d}_k^T A$ :

$$\mathbf{d}_k^T A \mathbf{d}_{k+1} = \mathbf{d}_k^T A \mathbf{r}_{k+1} + \beta_k \mathbf{d}_k^T A \mathbf{d}_k = 0$$

$$\therefore \beta_k = \frac{\mathbf{d}_k^T A \mathbf{r}_{k+1}}{\mathbf{d}_k^T A \mathbf{d}_k}$$



# Método Gradiente Conjugado

Algoritmo: Gradiente Conjugado (versão inicial)

$\mathbf{x}_0 =$  estimativa inicial

$\mathbf{d}_0 = \mathbf{r}_0 = \mathbf{b} - A\mathbf{x}$

**for**  $k = 0, 1, \dots, n - 1$  **do**

**if**  $\|\mathbf{r}_k\|_2 < tol$  **then**

**stop**

$$\alpha_k = \frac{\mathbf{d}_k^T \mathbf{r}_k}{\mathbf{d}_k^T A \mathbf{d}_k}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A \mathbf{d}_k$$

$$\beta_k = \frac{\mathbf{d}_k^T A \mathbf{r}_{k+1}}{\mathbf{d}_k^T A \mathbf{d}_k}$$

$$\mathbf{d}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{d}_k$$



# Método Gradiente Conjugado

Forma alternativa de determinar  $\alpha$

- Vimos que:

$$\alpha_k = \frac{\mathbf{d}_k^T \mathbf{r}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$

- Temos:

$$\mathbf{d}_k = \mathbf{r}_k + \beta_k \mathbf{d}_{k-1}$$

$$\mathbf{d}_k - \mathbf{r}_k = \beta_k \mathbf{d}_{k-1}$$

- Como  $\mathbf{d}_{k-1} \perp \mathbf{r}_k$ , podemos pré-multiplicar por  $\mathbf{r}_k^T$ :

$$\mathbf{r}_k^T \mathbf{d}_k - \mathbf{r}_k^T \mathbf{r}_k = \beta_k \mathbf{r}_k^T \mathbf{d}_{k-1} = 0$$

$$\mathbf{r}_k^T \mathbf{d}_k = \mathbf{r}_k^T \mathbf{r}_k = 0$$

- Logo,  $\alpha_k$  pode ser obtido por:

$$\alpha_k = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$



# Método Gradiente Conjugado

Forma alternativa de determinar  $\beta$

- Vimos que:

$$\beta_k = \frac{\mathbf{d}_k^T \mathbf{A} \mathbf{r}_{k+1}}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$

- Que pode ser re-escrito como:

$$\beta_k = \frac{\mathbf{r}_{k+1}^T \mathbf{r}_{k+1}}{\mathbf{r}_k^T \mathbf{r}_k}$$



# Método Gradiente Conjugado

Algoritmo: Gradiente Conjugado

$\mathbf{x}_0 =$  estimativa inicial

$\mathbf{d}_0 = \mathbf{r}_0 = \mathbf{b} - A\mathbf{x}$

**for**  $k = 0, 1, \dots, n - 1$  **do**

**if**  $\|\mathbf{r}_k\|_2 < tol$  **then**

**stop**

$$\alpha_k = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{d}_k^T A \mathbf{d}_k}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A \mathbf{d}_k$$

$$\beta_k = \frac{\mathbf{r}_{k+1}^T \mathbf{r}_{k+1}}{\mathbf{r}_k^T \mathbf{r}_k}$$

$$\mathbf{d}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{d}_k$$



# Método Gradiente Conjugado

Uso de preconditionadores

- ▶ Diminuir o número de condicionamento de  $A$
- ▶ Acelerar convergência

$$A\mathbf{x} = \mathbf{b}$$

$$M^{-1}A\mathbf{x} = M^{-1}\mathbf{b}$$

- ▶ onde  $M$  é o preconditionador



# Método Gradiente Conjugado

Uso de preconditionadores

- ▶ Diminuir o número de condicionamento de  $A$
- ▶ Acelerar convergência

$$A\mathbf{x} = \mathbf{b}$$

$$M^{-1}A\mathbf{x} = M^{-1}\mathbf{b}$$

- ▶ onde  $M$  é o preconditionador

Escolha do preconditionador

- ▶ O mais próximo de  $A$  possível
  - ▶ Para  $M^{-1}A$  resultar numa matriz bem condicionada
- ▶ Fácil de inverter





# Método Gradiente Conjugado

Uso de preconditionadores

- ▶ Diminuir o número de condicionamento de  $A$
- ▶ Acelerar convergência

$$A\mathbf{x} = \mathbf{b}$$

$$M^{-1}A\mathbf{x} = M^{-1}\mathbf{b}$$

- ▶ onde  $M$  é o preconditionador

Escolha do preconditionador

- ▶ O mais próximo de  $A$  possível
  - ▶ Para  $M^{-1}A$  resultar numa matriz bem condicionada
- ▶ Fácil de inverter

Escolhas extremas

- ▶  $M = A$ , resultaria na identidade
- ▶  $M = I$ , teria inversa trivial



# Método Gradiente Conjugado

Algoritmo: Gradiente Conjugado com Precondicionador

$x_0 =$  estimativa inicial

$r_0 = b - Ax$

$d_0 = z_0 = M^{-1}r_0$

**for**  $k = 0, 1, \dots, n - 1$  **do**

**if**  $\|r_k\|_2 < tol$  **then**

**stop**

$$\alpha_k = \frac{r_k^T z_k}{d_k^T A d_k}$$

$$x_{k+1} = x_k + \alpha_k d_k$$

$$r_{k+1} = r_k - \alpha_k A d_k$$

$$z_{k+1} = M^{-1} r_{k+1}$$

$$\beta_k = r_{k+1}^T z_{k+1} / r_k^T z_k$$

$$d_{k+1} = z_{k+1} + \beta_k d_k$$



# Método Gradiente Conjugado

Precondicionador de Jacobi

$$M = D$$

- Bom quando a matriz é estritamente diagonal dominante



# Método Gradiente Conjugado

Precondicionador de Jacobi

$$M = D$$

- Bom quando a matriz é estritamente diagonal dominante

Precondicionador simétrico sucessivo com sobrerelaxação  
(*Symmetrix Successive Over Relaxation* – SSOR)

$$M = (D + wL)D^{-1}(D + wU)$$

- com  $w \in [0, 2]$ 
  - Se  $w = 0$ , tem-se Jacobi
  - Se  $w = 1$ , tem-se Gauss-Seidel



# Método Gradiente Conjugado

Precondicionador de Jacobi

$$M = D$$

- ▶ Bom quando a matriz é estritamente diagonal dominante

Precondicionador simétrico sucessivo com sobrerelaxação  
(*Symmetrix Successive Over Relaxation* – SSOR)

$$M = (D + wL)D^{-1}(D + wU)$$

- ▶ com  $w \in [0, 2]$ 
  - ▶ Se  $w = 0$ , tem-se Jacobi
  - ▶ Se  $w = 1$ , tem-se Gauss-Seidel

Resolução de  $M\mathbf{z} = \mathbf{r}$

- ▶ Precondicionador SSOR é um produto de matrizes triangulares

$$(I + wLD^{-1})(D + wU)$$



## Exercícios propostos

1. Ache a fatoração de Cholesky  $A = R^T R$  para:

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 8 \end{bmatrix}$$

2. Qual a diferença entre o Método de Jacobi e o Método de Gauss-Seidel para solução iterativa de sistemas lineares?
3. No Método Gradiente Conjugado, qual a importância do uso de pré-condicionadores? O pré-condicionador de Jacobi é dado por  $M = D$ ; em que situações ele é adequado?
4. Sabe-se que o Método Gradiente Conjugado garantidamente converge após  $n$  iterações. Como cada iteração tem complexidade  $O(n^2)$ , devido às operações de multiplicação de matriz por vetor, garante-se que o método chega a solução do sistema em  $O(n^3)$ . O método de Eliminação de Gauss também tem complexidade  $O(n^3)$ . Descreva um cenário onde o método Gradiente Conjugado apresenta ordem de complexidade linear ( $O(n)$ ).

